

# ECONOMETRICS

## АЛЕКСАНДР ЛЕВКУН

### Содержание

<b>СМФ</b>	<b>2</b>
<b>Семинар. November, 24</b>	<b>4</b>
Условное математическое ожидание . . . . .	4
Задача про автобус на пуассоновский поток . . . . .	4
Задача про грибы . . . . .	4
Условная дисперсия . . . . .	5
Задача про 100 равномерно распределенных случайных величин . . . . .	5
<b>Семинар. December, 1</b>	<b>7</b>
Состоятельность оценок . . . . .	7
Задача на состоятельность коэффициентов регрессии . . . . .	7
Большой список хороших свойств касательно регрессии . . . . .	8
<b>Семинар. December, 8</b>	<b>10</b>
Гетероскедастичность . . . . .	10
Графический детекшн гетероскедастичности . . . . .	12
White test . . . . .	15
Goldfeld-Quandt test . . . . .	16
Breusch-Pagan test . . . . .	17
Домашнее задание. RLMS и гетероскедастичность . . . . .	18
<b>Семинар. January, 19</b>	<b>19</b>
Ограниченная и неограниченная модели . . . . .	19
Likelihood-ratio test . . . . .	19
Lagrange Multiplier test . . . . .	19
Wald test . . . . .	19
Задача на применение базовых тестов для проверки ограничений . . . . .	20
Задача на проверку ограничений на мат. ожидание и дисперсию . . . . .	23
<b>Семинар. January, 26</b>	<b>26</b>
Метод максимального правдоподобия . . . . .	26
Задача про плов и максимальное правдоподобие . . . . .	26
<b>Семинар. February, 2</b>	<b>32</b>
Логистическое распределение . . . . .	32
Логит и пробит модели . . . . .	35
Задача про Винни-Пуха и мед . . . . .	35

Задача про предельный эффект . . . . .	37
Задача про Фрекен Бок, коньяк и привидения . . . . .	38

<b>Семинар. February, 9</b>	<b>40</b>
Задача про оценку вероятности в логит модели . . . . .	42
Delta method . . . . .	44

<b>Семинар. February, 16</b>	<b>46</b>
------------------------------	-----------

## CMF

Есть КЛММР — классическая линейная модель множественной регрессии.

А есть ОЛММР — обобщенная линейная модель множественной регрессии — общий вид  $\Omega$  (нарушается условие гомоскедастичности и некоррелированных ошибок).

$$\hat{\beta}_{GLS} = (X'\Omega^{-1}X)^{-1}X'\Omega^{-1}y$$

Оценка, полученная методом ОМНК (GLS):

1. несмещенная;
2. состоятельная;
3. распределена нормально при нормальном распределении ошибок;
4. эффективная в классе несмещенных линейных оценок.

$$\text{Var}(\hat{\beta}_{OLS}) = (X'X)^{-1}X'\Omega X(X'X)^{-1}$$

Нужно уметь эффективно оценивать  $\Omega$ !

В КЛММР:

$$\hat{R}^2 = 1 - \frac{(y - X\hat{\beta}_{GLS})'(y - X\hat{\beta}_{GLS})}{(y - \bar{y}I)'(y - \bar{y}I)}$$

Но такая оценка  $R^2$  является смещенной. Поэтому используем несмещенную оценку:

$$\hat{R}_{adj}^2 = 1 - \frac{(y - X\hat{\beta}_{GLS})'(y - X\hat{\beta}_{GLS}) / (n - k)}{(y - \bar{y}I)'(y - \bar{y}I) / (n - 1)}$$

Про ограниченную модель. Выдвигается какая-то гипотеза о коэффициентах: в матричном виде  $H_0 : H\beta = r$ .

$F$ -статистика:

$$F = \frac{(H\hat{\beta} - r)'(H(X'X)^{-1}H')^{-1}(H\hat{\beta} - r)/q}{RSS/(n - k)}$$

Пример:

$$y_i = \beta_1 + \beta_2 x_i + \beta_3 z_i + \varepsilon_i$$

$$H_0 = \begin{cases} \beta_1 = 1 \\ \beta_2 = \beta_3 \end{cases}$$

Матрица  $H$  и вектор  $r$  здесь:

$$H = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & -1 \end{pmatrix}$$
$$r = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

Проверка гипотезы:  $H_0 : \beta_2 = \dots = \beta_k = 0$ .

$$F = \frac{R^2}{1 - R^2} \frac{n - k}{k - 1}$$

При верной  $H_0$ :  $F$ -статистика имеет распределение Фишера с  $k - 1$  и  $n - k$  степенями свободы.

Если хотим проверить, что  $q$  коэффициентов незначимы, то:

$$F = \frac{(R_{UR}^2 - R_R^2)/q}{(1 - R_{UR}^2)/(n - k)}$$

$$F = \frac{(RSS_R - RSS_{UR})/q}{RSS_{UR}/(n - k)}$$

Ну и оценка дисперсии:

$$\hat{\sigma}^2 = \frac{1}{n - k} \hat{\varepsilon}' \hat{\varepsilon}$$

## СЕМИНАР. NOVEMBER, 24

Перед тем, как переходить к стохастическим регрессорам, для начала вернемся к теории вероятности:

$Y$  — одна случайная величина;  $X$  — одна случайная величина.

Вспоминаем концепцию **условного математического ожидания**:  $\mathbb{E}(Y|X)$  — случайная величина.

$$\mathbb{E}(Y|X) = \mathbb{E}(Y|X = x_i) \text{ if } X = x_i$$

Основные свойства:

- $\mathbb{E}(a|X) = a$
- $\mathbb{E}(aY|X) = a\mathbb{E}(Y|X)$
- $\mathbb{E}(f(X)|X) = f(X)$
- $\mathbb{E}(\mathbb{E}(Y|X)) = \mathbb{E}(Y)$

**Задача 1.** Задача на пуассоновский поток ( $\lambda = 2$ ):

день 1: Вася ждет  $T$  до 1 автобуса

день 2: Вася ждет время  $T$ .  $N$  — кол-во автобусов за время  $T$ .

Найти:  $\mathbb{E}(N)$ ;  $\mathbb{E}(N^2)$ ; Правда ли, что  $N$  распределено по Пуассону?

Решение:

$$\mathbb{E}(N) = \mathbb{E}(\mathbb{E}(N|T))$$

$$N|T \sim Poiss(2 \cdot T)$$

Учитывая то, что для пуассоновского потока  $T \sim Exp(2)$ :

$$\mathbb{E}(N) = \mathbb{E}(\mathbb{E}(N|T)) = \mathbb{E}(2T) = 2 \cdot \frac{1}{2} = 1$$

$$\begin{aligned} \mathbb{E}(N^2) &= \mathbb{E}(\mathbb{E}(N^2|T)) = \mathbb{E}(\text{Var}(N|T) + (\mathbb{E}(N|T))^2) = \mathbb{E}(2T + 4T^2) = \\ &= 2\mathbb{E}T + 4\text{Var}(T) + 4(\mathbb{E}T)^2 = 1 + 1 + 1 = 3 \end{aligned}$$

Правда ли, что  $N$  распределено по Пуассону? Нет! Так как  $\text{Var} = 3 - 1 = 2 \neq \mathbb{E}(N)$ .

**Задача 2.** Задача про грибы:

$n$  грибов. Вероятности найти рыжик  $R$ , лисичку  $L$  или другой гриб соответственно равны  $p_r, p_l, 1 - p_r - p_l$ .

Найти:  $\mathbb{E}(R|L)$ ;  $\mathbb{P}(R = 0|L)$ ;  $\mathbb{P}(\mathbb{E}(R|L) = 0)$ ;  $\mathbb{E}[(\mathbb{E}(R|L))^2]$ .

Решение:

$$R|L \sim Bin\left(n - L, \frac{p_r}{1 - p_l}\right)$$

$$\mathbb{E}(R|L) = (n - L) \frac{p_r}{1 - p_l}$$

$$\begin{aligned}\mathbb{P}(R=0|L) &= \left(1 - \frac{p_r}{1-p_l}\right)^{n-L} \\ \mathbb{P}(\mathbb{E}(R|L)=0) &= \mathbb{P}(L=n) = p_l^n \\ \mathbb{E}[(\mathbb{E}(R|L))^2] &= \mathbb{E}(Y^2) = \mathbb{V}ar(Y) + (\mathbb{E}(Y))^2 = \mathbb{V}ar\left((n-L)\frac{p_r}{1-p_l}\right) + (\mathbb{E}(R))^2 = \\ &= \left(\frac{p_r}{1-p_l}\right)^2 \mathbb{V}ar(L) + n^2 p_r^2 = \left(\frac{p_r}{1-p_l}\right)^2 n p_l (1-p_l) + n^2 p_r^2 = n p_r^2 \left(\frac{p_l}{1-p_l} + n\right)\end{aligned}$$

**Условная дисперсия:**

$$\mathbb{V}ar(Y|X) = \mathbb{E}(Y^2|X) - (\mathbb{E}(Y|X))^2$$

Основные свойства условной дисперсии:

- $\mathbb{V}ar(aY|X) = a^2 \mathbb{V}ar(Y|X)$
- $\mathbb{V}ar(f(X)|X) = 0$
- $\mathbb{V}ar(XY|X) = X^2 \mathbb{V}ar(Y|X)$

Теорема Пифагора (by definition  $|y|^2 = \mathbb{V}ar(y)$ , скалярное произведение —  $(x, y) = \mathbb{C}ov(x, y)$ , критерий перпендикулярности:  $\mathbb{C}ov(x, y) = 0$ ):

$$\mathbb{V}ar(y) = \mathbb{E}(\mathbb{V}ar(y|x)) + \mathbb{V}ar(\mathbb{E}(y|x))$$

$\mathbb{C}ov(y - \mathbb{E}(y|x), \mathbb{E}(y|x)) = 0$  доказывается из теории меры.

Определение:

$\mathbb{E}(y|x)$  — это такая с.в.  $\hat{y}$ , что  $\hat{y} = f(x)$  (борелевская), что:  $\mathbb{E}(\hat{y}) = \mathbb{E}(y)$ ,  $\mathbb{C}ov(y, g(x)) = \mathbb{C}ov(\hat{y}, g(x))$  (или  $\mathbb{C}ov(y - \hat{y}, g(x)) = 0$ ), т.е.  $y$  и  $\hat{y}$  неотличимы в смысле мат. ожиданий и ковариаций.

**Задача 3.**  $X_1, X_2, \dots, X_{100} \sim \text{i.i.d } U[0, 1]$

$$M = \max\{X_1, \dots, X_{100}\}$$

$$L = \max\{X_1, \dots, X_{80}\}$$

$$R = \max\{X_{81}, \dots, X_{100}\}$$

Найти:  $\mathbb{P}(L > R|L)$ ,  $\mathbb{P}(L > R|R)$ ,  $\mathbb{P}(L > R|L, M)$ ,  $\mathbb{E}(M|L)$ ,  $\mathbb{E}(L|M)$ .

Решение:

$$\mathbb{P}(L > R|L) = \mathbb{P}(X_{81} < L|L) \cdot \mathbb{P}(X_{82} < L|L) \cdot \dots \cdot \mathbb{P}(X_{100} < L|L) = F^{20}(L) = L^{20}$$

$$\mathbb{P}(L > R|R) = 1 - \mathbb{P}(L < R|R) = 1 - \mathbb{P}(X_1 < R|R) \cdot \dots \cdot \mathbb{P}(X_{80} < R|R) = 1 - F^{80}(R) = 1 - R^{80}$$

Т.к.  $M = \max\{L, R\}$ ,  $\mathbb{P}(M = L) = 0.8$ ,  $\mathbb{P}(M = R) = 0.2$ , то:

$$\mathbb{P}(L > R|M) = \frac{4}{5} M^{20} + \frac{1}{5} (1 - M^{80})$$

$$\mathbb{P}(L > R|L, M) = \mathbf{1}_{L=M}$$

Заметим, что  $F_R(x) = x^{20}$ , тогда  $f_R(x) = 20x^{19}$ . Отсюда можем найти математическое ожидание случайной величины  $R$  (этот же результат можно получить из соображений симметрии):

$$\mathbb{E}(R) = \int_0^1 20x^{20} dx = \frac{20}{21}$$

$$\mathbb{E}(M|L) = \frac{4}{5}L + \frac{1}{5} \cdot \frac{20}{21} = \frac{4}{5}L + \frac{4}{21}$$

Учитывая то, что  $\mathbb{E}(L|M \neq L) = 80M/81$  (из соображений симметрии):

$$\mathbb{E}(L|M) = \frac{4}{5}M + \frac{1}{5} \cdot \frac{80}{81}M = \frac{404}{405}M$$

# СЕМИНАР. DECEMBER, 1

Последовательность оценок  $\hat{\theta}_1, \hat{\theta}_2, \hat{\theta}_3, \dots$  называется **состоятельной** для параметра  $\theta$ , если при  $n \rightarrow \infty$ :

$$\mathbb{P}(|\hat{\theta}_n - \theta| > \varepsilon) \rightarrow 0$$

Обозначение состоятельности:  $\text{plim} \hat{\theta}_n = \theta$  или  $\hat{\theta}_n \rightarrow \theta$

**Задача 1. а)**  $X$  — детерминированная. Оценивается модель парной регрессии:

$$y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$$

$$x_i = \begin{cases} 1, & \text{при } i = 1; \\ 2, & \text{при } i \geq 2. \end{cases}$$

$n = 3, 4, 5, 6, \dots$

Верно ли, что  $\text{plim}_{n \rightarrow \infty} \hat{\beta}_2^n = \beta_2$  ( $n$  здесь — не степень, а просто индекс)?

$$X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ \vdots & \vdots \\ 1 & 2 \end{pmatrix}$$

$$X'X = \begin{pmatrix} n & 2n-1 \\ 2n-1 & 4n-3 \end{pmatrix}$$

$$(X'X)^{-1} = \frac{1}{n-1} \begin{pmatrix} 4n-3 & -2n+1 \\ -2n+1 & n \end{pmatrix}$$

$$\text{Так как } \text{Var} \hat{\beta} = \sigma^2 (X'X)^{-1}, \text{ то: } \lim_{n \rightarrow \infty} \text{Var}(\hat{\beta}^n) = \sigma^2 \begin{pmatrix} 4 & -2 \\ -2 & 1 \end{pmatrix}$$

Итак,  $\text{Var}(\hat{\beta}_2^n) = \sigma^2$ ,  $\text{Var}(\hat{\beta}_1^n) = 4\sigma^2$ . Достаточное условие не выполняется.

Достаточными условиями состоятельности являются:

$$1. \text{Var}(\hat{\theta}_n) \rightarrow 0$$

$$2. \mathbb{E}(\hat{\theta}_n) = \theta$$

Пример, когда без выполнения условий Чебышева выполняется состоятельность:

$\hat{\theta}_n$	$\theta - 100^n$	$\theta$	$\theta + 100^n$
$\mathbb{P}(\hat{\theta}_n)$	$0.1^n$	$1 - 2 \cdot 0.1^n$	$0.1^n$

Оценка состоятельна, но  $\text{Var}(\hat{\theta}_n) \rightarrow \infty$ .

Докажем все же по-честному (выше мы просто показали, что достаточное условие состоятельности не выполняется):

$$X'\varepsilon = \begin{pmatrix} \varepsilon_1 + \varepsilon_2 + \dots + \varepsilon_n \\ \varepsilon_1 + 2\varepsilon_2 + \dots + 2\varepsilon_n \end{pmatrix}$$

Тогда:

$$\lim_{n \rightarrow \infty} (X'X)^{-1} X'\varepsilon = \begin{pmatrix} 4 & -2 \\ -2 & 1 \end{pmatrix} X'\varepsilon = \begin{pmatrix} 2\varepsilon_1 \\ -\varepsilon_1 \end{pmatrix}$$



$$\hat{\beta} = \beta + (X'X)^{-1} X'\varepsilon$$

$$\begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} \rightarrow \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix} + \begin{pmatrix} 2\varepsilon_1 \\ -\varepsilon_1 \end{pmatrix}$$

Из последнего следует несостоятельность оценок коэффициентов.

б) Теперь:

$$x_i = \begin{cases} 1, & \text{при } i = 2k + 1; \\ 2, & \text{при } i = 2k. \end{cases}$$

$$X'X = \begin{pmatrix} n & 3n/2 \\ 3n/2 & 5n/2 \end{pmatrix}$$

$$(X'X)^{-1} = \frac{4}{n^2} \begin{pmatrix} 5n/2 & -3n/2 \\ -3n/2 & n \end{pmatrix}$$

$$\lim_{n \rightarrow \infty} \text{Var}(\hat{\beta}^n) = \sigma^2 \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}$$

Оценки — состоятельны по достаточным условиям.

в) Теперь  $x_i = i$ .

Так как  $1^2 + 2^2 + \dots + n^2 = n(n+1)(2n+1)/6$  (доказывается по мат. индукции), то:

$$X'X = \begin{pmatrix} n & n(n+1)/2 \\ n(n+1)/2 & n(n+1)(2n+1)/6 \end{pmatrix}$$

Находим определитель:

$$\det(X'X) = \frac{n^2(n+1)(2n+1)}{6} - \frac{n^2(n+1)^2}{4} =$$

$$n^2(n+1) \frac{4n+2-3n-3}{12} = \frac{n(n+1)(n-1)}{12}$$

$$(X'X)^{-1} = \frac{12}{n(n+1)(n-1)} \begin{pmatrix} n(n+1)(2n+1)/6 & -n(n+1)/2 \\ -n(n+1)/2 & n \end{pmatrix} =$$

$$= \begin{pmatrix} 2(2n+1)/(n-1) & -6/(n-1) \\ -6/(n-1) & 12/(n+1)/(n-1) \end{pmatrix}$$

$$\text{Значит: } \lim_{n \rightarrow \infty} \text{Var}(\hat{\beta}^n) = \sigma^2 \begin{pmatrix} 4 & 0 \\ 0 & 0 \end{pmatrix}$$

Достаточно свойство не выполняется. Докажем снова по-честному:

$$X'\varepsilon = \begin{pmatrix} \varepsilon_1 + \varepsilon_2 + \dots + \varepsilon_n \\ \varepsilon_1 + 2\varepsilon_2 + \dots + n\varepsilon_n \end{pmatrix}$$

$$\lim_{n \rightarrow \infty} (X'X)^{-1} X'\varepsilon = \begin{pmatrix} 4 & 0 \\ 0 & 0 \end{pmatrix} X'\varepsilon = \begin{pmatrix} 4 \sum \varepsilon_i \\ 0 \end{pmatrix}$$

$$\hat{\beta} = \beta + (X'X)^{-1} X'\varepsilon$$

$$\begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} \rightarrow \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix} + \begin{pmatrix} 4 \sum \varepsilon_i \\ 0 \end{pmatrix}$$

Видим, что оценка коэффициента  $\beta_2$  — состоятельна, однако оценка коэффициента  $\beta_1$  не является состоятельной.

**БСХС** (Большой Список Хороших Свойств):

Если:

- $y = X\beta + \varepsilon$

- $\mathbb{E}(\varepsilon|X) = 0$
- $\mathbb{V}ar(\varepsilon|X) = \sigma^2 I_n$
- $P(X \text{ полного ранга}) = 1$
- векторы  $(x_{i2}, x_{i3}, \dots, x_{ik}, y_i) — \text{i.i.d.}$
- $n > k$
- строится регрессия  $y$  на  $X$

то:

1. Базовые:

- $\hat{\beta}$  — линейные по  $y$ :  $\hat{\beta} = (X'X)^{-1} X'y$
- $\mathbb{E}(\hat{\beta}|X) = \beta$
- $\mathbb{E}(\hat{\beta}) = \beta$
- условная эффективность среди линейных несмещенных оценок:  

$$\mathbb{V}ar\left(\hat{\beta}_j^{OLS}|X\right) \leq \mathbb{V}ar\left(\hat{\beta}_j^{alt}|X\right)$$
- безусловная эффективность среди линейных несмещенных оценок (следует из условной из теоремы Пифагора):  $\mathbb{V}ar\left(\hat{\beta}_j^{OLS}\right) \leq \mathbb{V}ar\left(\hat{\beta}_j^{alt}\right)$
- $\mathbb{E}(\hat{\sigma}^2) = \sigma^2$

2. Асимптотические:

- $\text{plim}\hat{\sigma}^2 = \sigma^2$
- $\text{plim}\hat{\beta} = \beta$
- $t \sim N(0, 1)$
- $qF \sim \chi_q^2$  (из restricted and unrestricted models)

3. При дополнительной предпосылке  $\varepsilon|X \sim N(0; \sigma^2 I_n)$ :

- $t|X \sim t_{n-k}$
- $t \sim t_{n-k}$
- $F|X \sim F_{q, n-k}$
- $F \sim F_{q, n-k}$
- $\hat{\sigma}^2(n-k)/\sigma^2|X \sim \chi_{n-k}^2$
- $\hat{\sigma}^2(n-k)/\sigma^2 \sim \chi_{n-k}^2$

## СЕМИНАР. DECEMBER, 8

Setup: Регрессоры стохастические, **гетероскедастичность**  $\text{Var}(\varepsilon|X) \neq \sigma^2$

В случайных выборках всегда присутствует гетероскедастичность.

Если есть гетероскедастичность (а она, скорее, есть!), то:

1.  $\mathbb{E}(\hat{\beta}) = \beta$
2.  $\text{Var}(\hat{\beta}|X) \neq \sigma^2 (X'X)^{-1}$

$$\text{Var}(\varepsilon|X) = \text{Var}(y|X) = \Omega$$

$$\text{Var}(\hat{\beta}|X) = \text{Var}((X'X)^{-1}X'y|X) = (X'X)^{-1}X'\Omega X(X'X)^{-1}$$

$$\widehat{\text{Var}}(\hat{\beta}|X) = (X'X)^{-1}X'\hat{\Omega}X(X'X)^{-1}$$

Уайт предложил оценки для  $\Omega$ : HC0, HC1, HC2, ...

Подгружаем пакеты:

```
library("lmtest") # тест Бройша-Пагана

## Loading required package: zoo
##
## Attaching package: 'zoo'
##
## The following objects are masked from 'package:base':
##
##   as.Date, as.Date.numeric

library("sandwich") # оценка дисперсии для гетероскедастичности
library("ggplot2")
library("hexbin")

str(diamonds) # data set, встроенный в пакет ggplot2

## 'data.frame': 53940 obs. of 10 variables:
## $ carat : num 0.23 0.21 0.23 0.29 0.31 0.24 0.24 0.26 0.22 0.23 ...
## $ cut : Ord.factor w/ 5 levels "Fair"<"Good"<...: 5 4 2 4 2 3 3 3 1 3 ...
## $ color : Ord.factor w/ 7 levels "D"<"E"<"F"<"G"<...: 2 2 2 6 7 7 6 5 2 5 ...
## $ clarity: Ord.factor w/ 8 levels "I1"<"SI2"<"SI1"<...: 2 3 5 4 2 6 7 3 4 5 ...
## $ depth : num 61.5 59.8 56.9 62.4 63.3 62.8 62.3 61.9 65.1 59.4 ...
## $ table : num 55 61 65 58 58 57 57 55 61 61 ...
## $ price : int 326 326 327 334 335 336 336 337 337 338 ...
## $ x : num 3.95 3.89 4.05 4.2 4.34 3.94 3.95 4.07 3.87 4 ...
## $ y : num 3.98 3.84 4.07 4.23 4.35 3.96 3.98 4.11 3.78 4.05 ...
## $ z : num 2.43 2.31 2.31 2.63 2.75 2.48 2.47 2.53 2.49 2.39 ...

model <- lm(log(price) ~ log(carat), data = diamonds)
```

```
summary(model)

##
## Call:
## lm(formula = log(price) ~ log(carat), data = diamonds)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.50833 -0.16951 -0.00591  0.16637  1.33793
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  8.448661   0.001365  6190.9  <2e-16 ***
## log(carat)   1.675817   0.001934   866.6  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.2627 on 53938 degrees of freedom
## Multiple R-squared:  0.933, Adjusted R-squared:  0.933
## F-statistic: 7.51e+05 on 1 and 53938 DF,  p-value: < 2.2e-16

vcov(model)

##              (Intercept)    log(carat)
## (Intercept) 1.862382e-06 1.477020e-06
## log(carat)  1.477020e-06 3.739604e-06

vcovHC(model)

##              (Intercept)    log(carat)
## (Intercept) 2.175479e-06 1.946888e-06
## log(carat)  1.946888e-06 4.112166e-06

vcovHC(model, type = "HC5") # HC5 очень похож на HC3, т.к. много наблюдений

##              (Intercept)    log(carat)
## (Intercept) 2.175367e-06 1.946783e-06
## log(carat)  1.946783e-06 4.111931e-06
```

$$\widehat{\text{Var}}(\hat{\beta}|X) = \frac{RSS}{n-k}(X'X)^{-1}$$

Heteroscedasticity consistent (HC):

$$\widehat{\text{Var}}(\hat{\beta}|X) = (X'X)^{-1}X'\hat{\Omega}X(X'X)^{-1}$$

Следующие команды используют не HC оценки:

```
coeftest(model)

##
```

```
## t test of coefficients:
##
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 8.4486607  0.0013647 6190.90 < 2.2e-16 ***
## log(carat)  1.6758167  0.0019338  866.59 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

confint(model)

##              2.5 %    97.5 %
## (Intercept) 8.445986 8.451336
## log(carat)  1.672026 1.679607
```

Поэтому указываем, какую ковариационную матрицу брать:

```
coeftest(model, vcov = vcovHC(model))

##
## t test of coefficients:
##
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 8.4486607  0.0014750  5728.1 < 2.2e-16 ***
## log(carat)  1.6758167  0.0020278   826.4 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

confint(model, vcov = vcovHC(model))

##              2.5 %    97.5 %
## (Intercept) 8.445986 8.451336
## log(carat)  1.672026 1.679607
```


Относительно «руками» доверительный интервал считается следующим образом:

```
low <- as.vector(coef(model) - qnorm(0.975)*sqrt(diag(vcovHC(model))))
high <- as.vector(coef(model) + qnorm(0.975)*sqrt(diag(vcovHC(model))))
conf <- data.frame(low, high)
conf

##      low      high
## 1 8.445770 8.451552
## 2 1.671842 1.679791
```


Попробуем задетектить гетероскедастичность с помощью графического анализа:

```
qplot(data = diamonds, log(carat), (resid(model))^2)
```



На таком графике ничего не видно. Попробуем увидеть черную кошку в черной комнате с помощью пакета *hexbin*:

```
qplot(data = diamonds, log(carat), (resid(model))^2) + geom_hex()
```



Видим, что с увеличением логарифма массы бриллианта растет дисперсия ошибки. Значит, есть гетероскедастичность.

Теперь попробуем выявлять и бороться с гетероскедастичностью теоретическими методами [Магнус, Пересецкий]. Итак, мы рассматриваем частный случай обобщенной регрессионной модели, а именно, модель с гетероскедастичностью. Это означает, что ковариационная матрица  $\Omega$  — диагональная.

Стандартные ошибки в форме Уайта:

$$\mathbb{V}ar(\hat{\beta}|X) = (X'X)^{-1}X'\Omega X(X'X)^{-1}$$

Уайт показал, что

$$\widehat{\mathbb{V}ar}(\hat{\beta}|X) = (X'X)^{-1}X'\hat{\Omega}X(X'X)^{-1}$$

является состоятельной оценкой ковариационной матрицы оценок коэффициентов регрессии.

Тесты на гетероскедастичность:

Во всех этих тестах проверяется основная гипотеза  $H_0 : \sigma_1^2 = \dots = \sigma_n^2$  против альтернативной гипотезы  $H_a : H_0 \text{ is not true}$ .

Большинство тестов есть априорные структурные ограничения относительно характера гетероскедастичности (из каких-либо разумных соображений). Однако тест Уайта освобожден от этих ограничений:

## 1 Тест Уайта (White)

Если в модели присутствуют гетероскедастичность, то очень часто это связано с тем, что дисперсии ошибок некоторым образом (возможно, сложным образом) зависят от регрессоров; гетероскедастичность должна как-то отражаться в остатках обычной регрессии исходной модели.

Сначала к исходной модели применяется обычный МНК и находятся остатки регрессии  $e_t$ . Затем осуществляется регрессия квадратов этих остатков на все регрессоры  $X$ , их квадраты, а также попарные произведения и константу (если ее не было в составе исходных регрессоров). Тогда при верной гипотезе  $H_0$  величина  $nR^2$  асимптотически имеет распределение  $\chi^2(N-1)$ , где  $N$  — число регрессоров вспомогательной регрессии.

Тест универсален, но в случае если  $H_0$  отвергается, он не дает никакого указания на форму гетероскедастичности; единственный способ коррекции — использование стандартных ошибок в форме Уайта.

[Демешев] Предпосылки:

- $H_0: Var(\varepsilon_i) = \sigma^2$ , нормальность не требуется;
- $E(\varepsilon_i^4) = const$ ;
- тест асимптотический;

Процедура:

- оценивается регрессия  $y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$ ;
- строим регрессию  $\hat{\varepsilon}_i^2$  на все регрессоры, их квадраты, их попарные произведения и константу (можно пойти и дальше, но разложение в Тейлора до членов, отвечающих за квадраты, уже дает хорошую точность);
- асимптотически  $nR^2$  имеет хи-квадрат распределение.

Тест Уайта в R:

```
e2 <- (model$residuals)^2
logcarat <- log(diamonds$carat)
wteststat <- summary(lm(e2 ~ logcarat + (logcarat^2)))$r.squared *
  length(model$fitted.values)
p.value <- 1 - pchisq(wteststat, df = length(model$coefficients) - 1)
p.value

## [1] 0
```



## 2 Тест Голдфелда-Куандта (Goldfeld-Quandt)

Применяется, когда есть предположение о прямой зависимости дисперсии ошибки от величины некоторой независимой переменной. Кратко тест можно описать следующим образом:

- упорядочить данные по убыванию той независимой переменной, относительно которой есть подозрение на гетероскедастичность;
- исключить  $d$  средних в этом упорядочении наблюдений ( $d$  должно быть равно примерно четверти общего количества наблюдений);
- провести две независимые регрессии первых  $n/2 - d/2$  наблюдений и последних  $n/2 - d/2$  наблюдений и построить соответствующие остатки  $e_1$  и  $e_2$ ;
- составить статистику  $F = e_1'e_1/e_2'e_2$ . Если верна гипотеза  $H_0$ , то  $F$  имеет распределение Фишера с  $(n/2 - d/2 - k, n/2 - d/2 - k)$  степенями свободы.

Большая величина этой статистики означает, что гипотезу  $H_0$  следует отвергнуть. Формально тест работает и без исключения наблюдений, но, как показывает опыт, при этом его мощность уменьшается.

[Демешев] Предпосылки:

- нормальность остатков,  $\varepsilon_i \sim N(0, \sigma_i^2)$ ;
- наблюдения упорядочены по возрастанию гетероскедастичности;
- тест точный (неасимптотический);

Процедура:

- упорядочить наблюдения в том порядке, в котором подозревается рост гетероскедастичности;
- выкинуть некий процент наблюдений по середине, чтобы подчеркнуть разницу в дисперсии между начальными и конечными наблюдениями;
- оценить исходную модель по наблюдениям из начала выборки и по наблюдениям конца выборки;
- получить, соответственно,  $RSS_1$  и  $RSS_2$ ;
- при верной  $H_0$ :

$$\frac{RSS_2}{RSS_1} \sim F_{r-k, r-k}$$

где  $r$  — размер подвыборки в начале и в конце.

Тест Голдфелда-Квандта в R:

```
diamonds2 <- diamonds[order(log(diamonds$carat)), ]  
# сменим порядок строк в табличке diamonds  
model2 <- lm(log(price) ~ log(carat), data = diamonds2)  
gqtest(model2, fraction = 0.2)
```

```
##
## Goldfeld-Quandt test
##
## data:  model2
## GQ = 1.3634, df1 = 21574, df2 = 21574, p-value < 2.2e-16

# проведем GQ тест выкинув посередине 20% наблюдений
```

### 3 Тест Бреуша-Пагана (Breusch-Pagan)

[Магнус, Пересецкий] Тест применяется в тех случаях, когда априорно предполагается, что дисперсии  $\sigma_t^2$  зависят от нескольких дополнительных переменных:

$$\sigma_t^2 = \gamma_0 + z_t' \gamma$$

В соответствии с этим тестом следует действовать так:

- провести обычную регрессию и получить вектор остатков  $e$ ;
- построить оценку  $\hat{\sigma}^2 = (1/n) \sum e_t^2$ ;
- провести регрессию  $e_t^2 / \hat{\sigma}^2 = \gamma_0 + z_t' \gamma + \nu_t$ , где  $\nu_t$  — белый шум, и найти для нее объясненную часть вариации  $ESS$ ;
- построить статистику  $ESS/2$ . При верной гипотезе  $H_0$ :  $ESS/2$  асимптотически имеет распределение  $\chi^2(p)$ , где  $p$  — длина вектора  $\gamma$ .

[Демешев] Предпосылки:

- нормальность остатков,  $\varepsilon_i \sim N(0, \sigma_i^2)$ ;
- $\sigma_i^2 = h(\alpha_1 + \alpha_2 z_{i2} + \dots + \alpha_p z_{ip})$ ;
- у функции  $h(\cdot)$  существуют первая и вторая производные;
- тест асимптотический.

Суть теста: Используя метод максимального правдоподобия посчитаем  $LM$ -статистику. При верной  $H_0$  она имеет хи-квадрат распределение с  $p - 1$  степенью свободы.

Оказывается, что  $LM$ -статистику можно получить с помощью вспомогательной регрессии. Авторская процедура:

Оценивается регрессия  $y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$ .

Переходим к  $g_i = n \hat{\varepsilon}_i / RSS$ .

Строим регрессию  $g_i$  на  $\alpha_1 + \alpha_2 z_{i2} + \dots + \alpha_p z_{ip}$ .

$LM = ESS/2$ .

Современная модификация выглядит (неизвестный рецензент Коэнкера) так:

Оценивается регрессия  $y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$ .

Оценивается регрессия  $s_i^2 = \alpha_1 + \alpha_2 x_i + \varepsilon_i$ .

При верной  $H_0$  асимптотически:

$$nR^2 \sim \chi_{p-1}^2$$

где  $p$  — число оцениваемых коэффициентов во вспомогательной регрессии. По смыслу  $(p - 1)$  — это количество факторов, от которых потенциально может зависеть дисперсия  $\text{Var}(\varepsilon_i)$ .

Тест Бройша-Пагана в R:

```
bptest(model)

##
## studentized Breusch-Pagan test
##
## data:  model
## BP = 411.6534, df = 1, p-value < 2.2e-16
```

Если хотя бы в одном из тестов  $H_0$  отвергается, делаем вывод о гетероскедастичности. Про прогнозирование:

КЛММР:

$$y = X\beta + \varepsilon; \varepsilon = 0, \text{Var}(\varepsilon) = \sigma^2 I$$

Предположим теперь, что есть еще один набор объясняющих переменных  $x_{n+1}$  и известно, что соответствующая зависимая переменная удовлетворяет модели:

$$y_{n+1} = x'_{n+1}\beta + \varepsilon_{n+1}; \mathbb{E}\varepsilon_{n+1} = 0, \text{Var}(\varepsilon)_{n+1} = \sigma^2 I, \text{Cov}(\varepsilon_{n+1}, \varepsilon) = 0$$

В качестве оценки  $y_{n+1}$  возьмем:

$$\hat{y}_{n+1} = x'_{n+1}\hat{\beta}$$

Стоит отметить, что где-то в этом временном промежутке необходимо было выполнить большое [Домашнее задание №1 про RLMS и гетероскедастичность](#).

$l(\theta)$  — логарифмическая функция максимального правдоподобия.

Рассмотрим три базовых теста, используемых для проверки ограничений на параметры статистических моделей. Все тесты асимптотические!

### 1 Тест отношения правдоподобия (LR-тест):

При верной  $H_0$ :

$$LR = 2 \left( l(\hat{\theta}_{UR}) - l(\hat{\theta}_R) \right) \sim \chi_q^2$$

Но на практике этот тест самый временозатратный, так как требует вычисления  $\hat{\theta}_{UR}$  и  $\hat{\theta}_R$ .

### 2 Тест множителей Лагранжа (LM-тест):

Информационная матрица (матрица Гессе с минусом):

$$\hat{I} = -\frac{\partial^2 l}{\partial \theta^2}(\theta)$$

При верной  $H_0$ :

$$LM = \left( \frac{\partial l}{\partial \theta}(\hat{\theta}_R) \right)' \cdot \hat{I}^{-1}(\hat{\theta}_R) \cdot \left( \frac{\partial l}{\partial \theta}(\hat{\theta}_R) \right) \sim \chi_q^2$$

### 3 Тест Вальда (Wald test):

$$H_0 : \begin{cases} g_1(\theta_1, \dots, \theta_p) = 0 \\ \dots \\ g_q(\theta_1, \dots, \theta_p) = 0 \end{cases}$$

При верной  $H_0$ :

$$W = \left( g(\hat{\theta}_{UR}) \right)' \cdot \left( \left( \frac{\partial l}{\partial \theta}(\hat{\theta}_{UR}) \right) \cdot \hat{I}^{-1}(\hat{\theta}_{UR}) \cdot \left( \frac{\partial l}{\partial \theta}(\hat{\theta}_{UR}) \right)' \right)^{-1} \cdot g(\hat{\theta}_{UR}) \sim \chi_q^2$$

Доказано, что тест Вальда ( $W$ ), тест отношения правдоподобия ( $LR$ ) и тест множителей Лагранжа ( $LM$ ) — асимптотически эквивалентные тесты ( $LM = LR = W$ ). Тем не менее для конечных выборок значения статистик не совпадают. Для линейных ограничений вкупе с рядом предпосылок доказано неравенство  $LM \leq LR \leq W$ . Тем самым тест Вальда будет чаще других тестов отвергать нулевую гипотезу об ограничениях. В случае нелинейных ограничений первая часть неравенства выполняется, а вторая — вообще говоря, нет.

**Задача 1.**  $X_1, \dots, X_n$  — независимы, 100 наблюдений;

$$f(x) = \frac{\theta e^{-\theta^2/2x}}{\sqrt{2\pi x^3}}, \quad x > 0$$

$$\sum_{x=1}^{100} \frac{1}{x_i} = 12$$

а)  $\hat{\theta}_{UR} - ?$

б)  $\hat{I}(\hat{\theta}_{UR}) - ?$

в) На уровне значимости  $\alpha = 5\%$  с помощью базовых тестов проверить гипотезу  $H_0: \theta = 1$

Решение.

а)

$$l(\theta) = \log(f(x_1) \cdot \dots \cdot f(x_n)) = \sum \log f(x_i) = \sum \left[ \log \theta - \frac{\theta^2}{2x_i} - \frac{1}{2} \log(2\pi) - \frac{3}{2} \log(x_i) \right] =$$

$$= n \log(\theta) - \theta^2 \sum \frac{1}{2x_i} - \frac{n}{2} \log(2\pi) - \frac{3}{2} \sum \log(x_i)$$

$$\frac{\partial l(\theta)}{\partial \theta} = \frac{n}{\theta} - 2\theta \sum \frac{1}{2x_i} = \frac{100}{\theta} - 12\theta$$

$$\frac{100}{\hat{\theta}_{UR}} - 12 \cdot \hat{\theta}_{UR} = 0$$

$$\hat{\theta}_{UR} = \sqrt{100/12} \approx 2.887$$

Проделаем тоже самое в R с помощью пакета *maxLik*:

```
library(maxLik)
```

```
## Loading required package: miscTools
```

```
##
```

```
## Please cite the 'maxLik' package as:
```

```
## Henningsen, Arne and Toomet, Ott (2011). maxLik: A package for maximum likelihood estimation in R. Computational Statistics 26(3), 443-458. DOI 10.1007/s00180-010-0217-1.
```

```
##
```

```
## If you have questions, suggestions, or comments regarding the 'maxLik' package, please use a forum or 'tracker' at maxLik's R-Forge site:
```

```
## https://r-forge.r-project.org/projects/maxlik/
```

Создаем случайную выборку:

```
a <- runif(n = 100, 0, 1)
```

Для выполнения ограничения масштабируем ее:

```

b <- 12*a/sum(a)
sum(b)

## [1] 12

x <- 1/b
head(x)

## [1] 32.594936 7.423517 4.689954 20.583336 306.203293 8.220522

sum(1/x)

## [1] 12

```

Функция, возвращающая значение логарифмической функции максимального правдоподобия:

```

lik <- function(theta, data){
  n <- length(data)
  ans <- n * log(theta) - theta^2*sum(1/(2*data)) - n*log(2*pi)/2 -
    3*sum(log(data))/2
  return(ans)
}
lik(1, x)

## [1] -450.2164

```

Максимизация:

```

model <- maxLik(lik, start = 1, data = x)
summary(model)

## -----
## Maximum Likelihood estimation
## Newton-Raphson maximisation, 6 iterations
## Return code 1: gradient close to zero
## Log-Likelihood: -388.2032
## 1 free parameters
## Estimates:
##      Estimate Std. error t value Pr(> t)
## [1,] 2.8868      0.2042  14.14 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## -----

```

$\hat{\theta}_{UR}$ :

```

model$estimate

## [1] 2.886751

```

б)

Гессиан:

$$\frac{\partial^2 l}{\partial \theta^2}(\hat{\theta}_{UR}) = -\frac{n}{\hat{\theta}_{UR}^2} - \sum \frac{1}{x_i} = \frac{100}{2.887^2} - 12 \approx -24$$

Или так:

```
model$hessian
```

```
##           [,1]  
## [1,] -23.98792
```

Тогда:

$$\hat{I}(\hat{\theta}_{UR}) = 24$$

в)

$\hat{\theta}_{UR}$ :

```
theta_ur <- model$estimate
```

$\hat{\theta}_R$  берем из гипотезы:

```
theta_r <- 1
```

$LR$ -тест:

```
LR <- -2*(lik(theta_r, data = x) - lik(theta_ur, data = x))  
LR  
  
## [1] 124.0264  
  
qcrit <- qchisq(0.95, df = 1); qcrit  
  
## [1] 3.841459  
  
LR < qcrit  
  
## [1] FALSE
```

Гипотеза отвергается.

Wald test:

```
I_ur <- -model$hessian  
g_ur <- theta_ur - 1  
dg_dtheta_ur <- 1  
W <- t(g_ur) %*% solve(dg_dtheta_ur %*% solve(I_ur) %*%  
                      t(dg_dtheta_ur)) %*% g_ur  
W <- as.integer(W); W  
  
## [1] 85  
  
W < qcrit  
  
## [1] FALSE
```

Гипотеза отвергается.

$LM$ -тест:

```
dl_dtheta_r <- 100/theta_r - 12*theta_r
LM <- t(dl_dtheta_r) %*% solve(I_ur) %*% dl_dtheta_r
LM <- as.integer(LM); LM

## [1] 322

LM < qcrit

## [1] FALSE
```

Гипотеза отвергается.

Как видим, здесь не выполняется соотношение между  $LR$ ,  $LM$  и  $W$ , о котором шла речь выше. Проблема в том, что здесь  $|W/n| < 1$  (подробнее в [Ullah A., Zinde-Walsh V. On the robustness of LM, LR, and W tests in regression models //Econometrica: Journal of the Econometric Society. – 1984.](#))

**Задача 2.**  $x_1, \dots, x_{100} — \text{i. i. d. } \mathcal{N}(\mu, \sigma^2)$

$$\sum x_i = 10$$

$$\frac{\sum (x_i - \bar{x})^2}{n - 1} = 5 = s_x^2$$

а)  $H_0 : \mu = \sigma^2$

б)  $H_0 : \begin{cases} \mu = 4 \\ \sigma^2 = 7 \end{cases}$

Решение.

а)

Функция плотности нормального распределения:

$$f(x_i) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

Тогда логарифмическая функция максимального правдоподобия здесь:

$$\begin{aligned} l(\mu, \sigma) &= \log(f(x_1) \cdot \dots \cdot f(x_{100})) = \sum \log f(x_i) = \\ &= \sum \left[ -\log(\sqrt{2\pi}) - \log \sigma - \frac{(x_i - \mu)^2}{2\sigma^2} \right] \end{aligned}$$

Берем первые производные:

$$\begin{aligned} \frac{\partial l(\cdot)}{\partial \mu} &= -\frac{2 \sum (x_i - \mu)}{2\sigma^2} = -\frac{\sum x_i - n\mu}{\sigma^2} \\ \frac{\partial l(\cdot)}{\partial \sigma} &= -\frac{n}{\sigma} + \frac{\sum (x_i - \mu)^2}{\sigma^3} = -\frac{n}{\sigma} + \frac{\sum (x_i - \bar{x})^2 + 2 \sum (x_i - \bar{x})(\bar{x} - \mu) + \sum (\bar{x} - \mu)^2}{\sigma^3} \end{aligned}$$



Из F.O.C.:

$$\hat{\mu} = \frac{\sum x_i}{n} = \bar{x} = 0.1$$

$$\hat{\sigma}^2 = \frac{\sum (x_i - \bar{x})^2}{n} = \frac{n-1}{n} s_x^2 = 4.95$$

Теперь найдем оценки максимального правдоподобия при ограничении из гипотезы  $\mu = \sigma^2$ :

$$l(\mu, \sigma) = \sum \left[ -\log(\sqrt{2\pi}) - \frac{1}{2} \log \mu - \frac{(x_i - \mu)^2}{2\mu} \right]$$

Первая производная:

$$\begin{aligned} \frac{\partial l(\cdot)}{\partial \mu} &= -\frac{n}{2\mu} - \frac{1}{2} \sum \frac{-2(x_i - \mu)\mu - (x_i - \mu)^2}{\mu^2} = \\ &= -\frac{n}{2\mu} - \frac{1}{2} \frac{-2\mu \sum x_i + 2n\mu^2 - \sum [(x_i - 0.1)^2 + 2(x_i - 0.1)(0.1 - \mu) + (0.1 - \mu)^2]}{\mu^2} = \\ &= -\frac{100}{2\mu} - \frac{1}{2} \frac{-20\mu + 200\mu^2 - 495 - 100(0.1 - \mu)^2}{\mu^2} \end{aligned}$$

F.O.C.:

$$\begin{aligned} -100\hat{\mu} + 20\hat{\mu} - 200\hat{\mu}^2 + 495 + 1 - 20\hat{\mu} + 100\hat{\mu}^2 &= 0 \\ \hat{\mu}^2 + \hat{\mu} - 4.96 &= 0 \end{aligned}$$

Учитывая, что  $\mu \geq 0$ :

$$\hat{\mu} = \frac{-1 + \sqrt{1 + 4 \cdot 4.96}}{2} \approx 1.7825$$

Итак:

$$\hat{\mu}_{UR} = 0.1, \hat{\sigma}_{UR}^2 = 4.95, \hat{\mu}_R = \hat{\sigma}_R^2 = 1.7825$$

$$l(\hat{\mu}_{UR}, \hat{\sigma}_{UR}) = -100 \log(\sqrt{2\pi}) - 100 \log \sqrt{4.95} - \frac{\sum (x_i - 0.1)^2}{2 \cdot 4.95} \approx -221.86$$

$$l(\hat{\mu}_R, \hat{\sigma}_R) = -100 \log(\sqrt{2\pi}) - 100 \log \sqrt{1.7825} - \frac{\sum (x_i - 1.7825)^2}{2 \cdot 1.7825} \approx$$

$$\approx -120.79 - \frac{\sum [(x_i - 0.1)^2 - 2 \cdot 1.6825 \cdot (x_i - 0.1) + 1.6825^2]}{3.565} =$$

$$\approx -120.79 - \frac{497.83}{3.565} \approx -260.43$$

Применив тест отношения правдоподобия, получим:

$$LR = 2(l(\hat{\mu}_{UR}, \hat{\sigma}_{UR}) - l(\hat{\mu}_R, \hat{\sigma}_R)) = 77.14$$

P-value:

```
1 - pchisq(77.14, df = 2)
```

```
## [1] 0
```

б)

Здесь:

$$\hat{\mu}_{UR} = 0.1, \hat{\sigma}_{UR}^2 = 4.95, \hat{\mu}_R = 4, \hat{\sigma}_R^2 = 7$$

$$l(\hat{\mu}_{UR}, \hat{\sigma}_{UR}) = -100 \log(\sqrt{2\pi}) - 100 \log \sqrt{4.95} - \frac{\sum (x_i - 0.1)^2}{2 \cdot 4.95} \approx -221.86$$

$$l(\hat{\mu}_R, \hat{\sigma}_R) = -100 \log(\sqrt{2\pi}) - 100 \log \sqrt{7} - \frac{\sum (x_i - 4)^2}{2 \cdot 7} \approx$$

$$\approx -189.19 - \frac{\sum [(x_i - 0.1)^2 - 2 \cdot 3.9 \cdot (x_i - 0.1) + 3.9^2]}{14} =$$

$$= -189.19 - \frac{5 \cdot 99 + 0 + 100 \cdot 3.9^2}{14} = -333.19$$

Применив тест отношения правдоподобия, получим:

$$LR = 2(l(\hat{\mu}_{UR}, \hat{\sigma}_{UR}) - l(\hat{\mu}_R, \hat{\sigma}_R)) = 222.66$$

P-value:

```
1 - pchisq(222.66, df = 2)
```

```
## [1] 0
```

Гипотеза отвергается.

### Метод максимального правдоподобия

Оценки максимального правдоподобия, вообще говоря, могут быть смещёнными, но являются состоятельными, асимптотически эффективными и асимптотически нормальными оценками. Асимптотическая нормальность означает, что:

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, I_{\infty}^{-1})$$

где  $I_{\infty} = -\lim_{n \rightarrow \infty} (\mathbb{E}(H)/n)$  — асимптотическая информационная матрица.

Асимптотическая эффективность означает, что асимптотическая ковариационная матрица  $I_{\infty}^{-1}$  является нижней границей для всех состоятельных асимптотически нормальных оценок.

Если  $\hat{\theta}$  — оценка метода максимального правдоподобия параметров  $\theta$ , то  $g(\hat{\theta})$  является оценкой максимального правдоподобия для  $g(\theta)$ , где  $g(\cdot)$  — непрерывная функция (функциональная инвариантность). Таким образом, законы распределения данных можно параметризовать различным образом.

Задачу ограниченной оптимизации лучше приводить к задаче неограниченной оптимизации.

Например:

Ограничение  $p \in [0, 1]$  с помощью сигмиды приводим к  $p = 1/(1 + e^{-t})$ , где  $t \in (-\infty, +\infty)$ .

Ограничение  $\sigma \in (0, +\infty)$  заменяем на  $\sigma = e^t$ , где  $t \in (-\infty, +\infty)$ .

### Задача 1.

Если  $X \sim \text{Pois}(\lambda)$ , то  $\mathbb{E}(X) = \lambda$ ,  $\text{Var}(X) = \lambda$ .

Но на реальных данных  $\mathbb{E}(X) \neq \text{Var}(X)$  из-за того, что нули попадаются слишком часто.

Пусть  $X_i$  — число кусков мяса в плове для  $i$ -го посетителя столовой. Например, Аня может быть любителем плова с вероятностью  $p$ , в этом случае  $X_i \sim \text{Pois}(\lambda)$ ; а может быть принципиальной его ненавистницей с вероятностью  $1 - p$ , тогда  $X_i = 0$ .

- а) Найти  $\hat{p}$ ,  $\hat{\lambda}$  с помощью метода максимального правдоподобия
- б) Построить доверительные интервалы для полученных оценок
- в) С помощью базовых тестов проверить гипотезу  $H_0: \lambda = 1$
- г) С помощью базовых тестов проверить гипотезу  $H_0: p = \lambda$

Решение.

- а) Для начала нужно понять, что мы будем оптимизировать:

$$\mathbb{P}(X_i = x) = \begin{cases} (1 - p) + pe^{-\lambda}, & x = 0 \\ pe^{-\lambda} \lambda^x / x!, & x > 0 \end{cases}$$

Taking logs:

$$\log(\mathbb{P}(X_i = x)) = \begin{cases} \log(1 - p + pe^{-\lambda}), & x = 0 \\ \log p - \lambda + x \log \lambda - \log x!, & x > 0 \end{cases}$$

Например, если в среднем в порцию плова кидают два куска мяса:

```
library(maxLik)

set.seed(4) # for reproducible results
# more on
# http://stackoverflow.com/questions/13605271/reasons-for-using-the-set-seed-function

X <- rpois(n = 100, lambda = 2)
head(X)

## [1] 2 0 1 1 3 1
```

Функция, которую будем оптимизировать:

```
loglik <- function(par, data) {
  p <- par[1]
  lambda <- par[2]
  n <- length(data)
  n_zero <- sum(data == 0)
  ans <- n_zero*log(1 - p + p*exp(-lambda))
  nonzero_data <- data[data > 0]
  ans <- ans + (n - n_zero)*(log(p) - lambda) +
    log(lambda)*sum(nonzero_data)
  return(ans)
}
```

Например, для  $p = 0.5$ ,  $\lambda = 1$  значение логарифмической функции правдоподобия для данных  $X$  будет равно:

```
loglik(c(0.5, 1), X)

## [1] -152.2423
```

Но мы знаем, что есть ограничения  $p \in [0, 1]$  и  $\lambda \in (0, +\infty)$ . То есть фактически мы имеем дело с условной оптимизацией. Что ж, перейдем к безусловной оптимизации с помощью функции-трансформера:

```
transformer <- function(par, data) {
  p <- 1/(1 + (exp(par[1]))^(-1)) # сигмоида
  lambda <- exp(par[2]) # экспонента
  return(c(p, lambda))
}

loglik2 <- function(par, data) {
  return(loglik(transformer(par), data))
}

result <- maxLik(logLik = loglik2, start = c(0,0), data = X)
report <- summary(result)
report
```

```
## -----
## Maximum Likelihood estimation
## Newton-Raphson maximisation, 9 iterations
## Return code 1: gradient close to zero
## Log-Likelihood: -41.27094
## 2 free parameters
## Estimates:
##      Estimate Std. error t value Pr(> t)
## [1,]  3.22389    1.15525   2.791 0.00526 **
## [2,]  0.85439    0.07701  11.094 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## -----
```

```
result$estimate
```

```
## [1] 3.223893 0.854393
```

```
transformer(result$estimate)
```

```
## [1] 0.9617236 2.3499476
```

Итак:  $\hat{p} = 0.9617236$ ,  $\hat{\lambda} = 2.3499476$

б) Строим 95 – % доверительные интервалы для полученных оценок:

```
high <- transformer(result$estimate + qnorm(0.975)*report$estimate[,2])
low  <- transformer(result$estimate - qnorm(0.975)*report$estimate[,2])
conf <- data.frame(low, high, row.names = c('p', 'lambda'))
conf
```

```
##           low      high
## p      0.7230517 0.9958815
## lambda 2.0207196 2.7328154
```

в) Мы уже знаем, что:

$$\hat{p}_{UR} = 0.9617236, \hat{\lambda}_{UR} = 2.3499476$$

При этом:

```
loglik(c(transformer(result$estimate)[1], transformer(result$estimate)[2]), X)

## [1] -41.27094
```

По условию  $\hat{\lambda}_R = 1$ . Нам нужно найти  $\hat{p}_R$  посредством максимизации логарифмической функции правдоподобия с подставлением в нее  $\hat{\lambda}_R = 1$ .

Нужно будет немного переписать функции:

```
loglik_restr <- function(p, data) {
  n <- length(data)
  n_zero <- sum(data == 0)
  ans <- n_zero*log(1 - p + p*exp(-1))
  nonzero_data <- data[data > 0]
  ans <- ans + (n - n_zero)*(log(p) - 1)
  return(ans)
}
```

```
transformer_restr <- function(p, data) {
  p_log <- 1/(1 + exp(p)^(-1)) # сизмолда
  return(p_log)
}
```

```
loglik2_restr <- function(p, data) {
  return(loglik_restr(transformer_restr(p), data))
}
```

```
result_restr <- maxLik(logLik = loglik2_restr, start = 0, data = X)
report_restr <- summary(result_restr)
report_restr
```

```
## -----
## Maximum Likelihood estimation
## Newton-Raphson maximisation, 10 iterations
## Return code 1: gradient close to zero
## Log-Likelihood: -100
## 1 free parameters
## Estimates:
##      Estimate Std. error t value Pr(> t)
## [1,]      8962          Inf      0      1
## -----
```

```
transformer_restr(result_restr$estimate)
```

```
## [1] 1
```

Значение логарифмической функции распределения в ограниченной модели:

```
loglik_restr(transformer_restr(result_restr$estimate), X)
```

```
## [1] -100
```

Для проверки гипотезы  $H_0: \lambda = 1$  ограничимся тестом отношения правдоподобия:

```
LR <- 2*( loglik(c(transformer(result$estimate)[1],
  transformer(result$estimate)[2]), X) -
  loglik_restr(transformer_restr(result_restr$estimate), X) )
```

```
LR
```

```
## [1] 117.4581
```

```
p.value <- 1 - pchisq(LR, df = 1)
p.value
```

```
## [1] 0
```

Гипотеза отвергается.

г)

Для проверки данной гипотезы снова придется переписать функцию, которую мы будем оптимизировать:

```
loglik_restr2 <- function(p, data) {
  n <- length(data)
  n_zero <- sum(data == 0)
  ans <- n_zero*log(1 - p + p*exp(-p))
  nonzero_data <- data[data > 0]
  ans <- ans + (n - n_zero)*(log(p) - p) +
    log(p)*sum(nonzero_data)
  return(ans)
}

loglik2_restr2 <- function(p, data) {
  return(loglik_restr2(transformer_restr(p), data))
}

result_restr2 <- maxLik(logLik = loglik2_restr2, start = 0, data = X)
report_restr2 <- summary(result_restr2)
report_restr2

## -----
## Maximum Likelihood estimation
## Newton-Raphson maximisation, 11 iterations
## Return code 1: gradient close to zero
## Log-Likelihood: -100
## 1 free parameters
## Estimates:
##      Estimate Std. error t value Pr(> t)
## [1,]      3477          Inf      0      1
## -----
```

```
transformer_restr(result_restr2$estimate)
```

```
## [1] 1
```

Снова применим  $LR$ -тест, и снова гипотеза будет отвергнута:

```
LR <- 2*( loglik(c(transformer(result$estimate)[1],
                    transformer(result$estimate)[2]), X) -
  loglik_restr2(transformer_restr(result_restr2$estimate), X) )
LR
```

```
## [1] 117.4581

p.value <- 1 - pchisq(LR, df = 2)
p.value

## [1] 0
```



## СЕМИНАР. FEBRUARY, 2

### Метод максимального правдоподобия применительно к `logit` и `probit` моделям

Для начала нужно познакомиться с логистическим распределением:

$X \sim L(0, 1)$ , если


$$f_X(x) = \frac{e^{-x}}{(1 + e^{-x})^2}$$

В общем виде:  $X \sim L(\mu, s)$ , если:

$$f_X(x) = \frac{e^{-(x-\mu)/s}}{s(1 + e^{-(x-\mu)/s})^2} = \frac{1}{4s} \cdot \operatorname{sech}^2\left(\frac{x - \mu}{2s}\right)$$

где  $\mu$  — параметр сдвига,  $s$  — параметр масштаба. Построим функцию плотности логистического распределения:

```
library(ggplot2)
x <- seq(-4, 4, by = 0.05)
y <- dlogis(x, location = 0, scale = 1)
qplot(x, y, geom = 'line')
```



Легко показать, что  $f_X(x)$  является четной:


$$f(-x) = \frac{e^x}{(1 + e^x)^2} = \frac{e^{-x}}{(1 + e^{-x})^2} = f(x)$$

Выведем функцию распределения логистического распределения:

$$F_X(x) = \int_{-\infty}^x \frac{e^{-x}}{(1 + e^{-x})^2} dx = \frac{1}{1 + e^{-x}} \Big|_{-\infty}^x = \frac{1}{1 + e^{-x}}$$

Достоинством логистического распределения является интегрируемость функции плотности. Заметим, что функция распределения логистического распределения — стандартная сигмоида:

```
yf <- plogis(x)
qplot(x, yf, geom = 'line')
```



Квантильная функция:

$$F^{-1}(p) = \log\left(\frac{p}{1-p}\right)$$

Так как  $f(x)$  является четной, то функция  $xf(x)$  является нечетной, что значит, что  $\mathbb{E}X = 0$ .

Если  $Z = \sqrt{3}/\pi \cdot X$ , то есть параметр масштаба  $s = \sqrt{3}/\pi$ , то:

$$f_Z(z) = \frac{\pi}{\sqrt{3}} \cdot \frac{e^{-\pi z/\sqrt{3}}}{(1 + e^{-\pi z/\sqrt{3}})^2}$$

Можно показать, что  $\text{Var}X = \pi^2/3$ . Например, так:


```
r <- rlogis(10^6)
var(r); pi^2/3

## [1] 3.286736
## [1] 3.289868
```

Значит,  $\text{Var}X = 1$ . Функция плотности случайной величины  $Z$  является хорошей аппроксимацией функции плотности стандартного нормального распределения.

Покажем это, двумя способами организовав данные:

```
yl <- dlogis(x, location = 0, scale = sqrt(3)/pi)
yn <- dnorm(x)
data <- data.frame(x = x, yl = yl, yn = yn)
qplot(data = data, x, yl, geom = 'line') + geom_line(aes(y = yn))
```




```
library(reshape2) # перевод данных из широкого формата в длинный
```

```
data_long <- melt(data = data, id.vars = 'x')
head(data_long)
```

```
##      x variable      value
## 1 -4.00      y1 0.001279628
## 2 -3.95      y1 0.001400914
## 3 -3.90      y1 0.001533677
## 4 -3.85      y1 0.001678999
## 5 -3.80      y1 0.001838062
## 6 -3.75      y1 0.002012160
```

```
qplot(data = data_long, x = x, y = value, col = variable, geom = 'line')
```



Длинный формат очень удобен для автоматической обработки данных. Из длинного формата в широкий переводит команда *cast*.

## Логит и пробит модели

$y_i \in \{0, 1\}$  — прогулял лекцию или нет (наблюдаема);

$y^*$  — склонность прогулять лекцию (ненаблюдаема);

Построим следующую модель:

$$y_i^* = \beta_1 + \beta_2 x_i + \beta_3 z_i + \varepsilon_i$$

Отличие логит модели от пробит модели:

- Логит:  $\varepsilon_i \sim L(0, 1)$
- Пробит:  $\varepsilon_i \sim N(0, 1)$

Для логистической модели:

$$\mathbb{P}(y_i = 1) = \mathbb{P}(\beta_1 + \beta_2 x_i + \beta_3 z_i + \varepsilon_i \geq 0) = \mathbb{P}(\varepsilon_i \geq -(\beta_1 + \beta_2 x_i + \beta_3 z_i)) = \frac{e^{\beta_1 + \beta_2 x_i + \beta_3 z_i}}{1 + e^{\beta_1 + \beta_2 x_i + \beta_3 z_i}}$$

$$\mathbb{P}(y_i = 0) = 1 - \mathbb{P}(y_i = 1) = \frac{1}{1 + e^{\beta_1 + \beta_2 x_i + \beta_3 z_i}}$$

Когда имеешь дело с логистической моделью, необходимо мыслить в отношениях шансов:

$$\log \left( \frac{\mathbb{P}(y_i = 1)}{\mathbb{P}(y_i = 0)} \right) = \beta_1 + \beta_2 x_i + \beta_3 z_i$$

### Задача 6.6.

Винни-Пух знает, что мёд бывает правильный,  $honey_i = 1$ , и неправильный,  $honey_i = 0$ . Пчёлы также бывают правильные,  $bee_i = 1$ , и неправильные,  $bee_i = 0$ . По 100 своим попыткам добыть мёд Винни-Пух составил таблицу сопряженности:

	$honey_i = 1$	$honey_i = 0$
$bee_i = 1$	12	36
$bee_i = 0$	32	20

Используя метод максимального правдоподобия, Винни-Пух хочет оценить логит модель для прогнозирования правильности мёда с помощью правильности пчёл:

$$\log \left( \frac{\mathbb{P}(honey_i = 1)}{\mathbb{P}(honey_i = 0)} \right) = \beta_1 + \beta_2 bee_i$$

- а) Выпишите функцию правдоподобия для оценки параметров  $\beta_1$  и  $\beta_2$
- б) Оцените неизвестные параметры
- в) С помощью теста отношения правдоподобия проверьте гипотезу о том, правильность пчёл не связана с правильностью мёда на уровне значимости 5 %
- г) Держась в небе за воздушный шарик, Винни-Пух неожиданно понял, что перед ним неправильные пчёлы. Помогите ему оценить вероятность того, что они делают неправильный мёд

Решение.

а) Будем оценивать склонность меда к правильности от правильности пчел:

$$honey_i^* = \beta_1 + \beta_2 bee_i + \varepsilon_i$$

Логарифмическая функция правдоподобия:

$$l(\beta_1, \beta_2, data) = \sum \log \mathbb{P}(honey_i(\omega) = honey_i | bee_i)$$

То есть мы ввели случайную величину — условную правильность меда.

Найдем все необходимые условные вероятности:

$$\mathbb{P}(honey_i = 1 | bee_i = 1) = \frac{e^{\beta_1 + \beta_2}}{1 + e^{\beta_1 + \beta_2}}$$

$$\mathbb{P}(honey_i = 1 | bee_i = 0) = \frac{e^{\beta_1}}{1 + e^{\beta_1}}$$

$$\mathbb{P}(honey_i = 0 | bee_i = 1) = \frac{1}{1 + e^{\beta_1 + \beta_2}}$$

$$\mathbb{P}(honey_i = 0 | bee_i = 0) = \frac{1}{1 + e^{\beta_1}}$$

Учитывая данные из таблички выше:

$$\begin{aligned} l(\beta_1, \beta_2, data) &= 12 \log \left( \frac{e^{\beta_1 + \beta_2}}{1 + e^{\beta_1 + \beta_2}} \right) + 32 \log \left( \frac{e^{\beta_1}}{1 + e^{\beta_1}} \right) + \\ &+ 36 \log \left( \frac{1}{1 + e^{\beta_1 + \beta_2}} \right) + 20 \log \left( \frac{1}{1 + e^{\beta_1}} \right) = \\ &= 44\beta_1 + 12\beta_2 - 48 \log(1 + e^{\beta_1 + \beta_2}) - 52 \log(1 + e^{\beta_1}) \end{aligned}$$

б) Найдем сначала первые производные функции  $l(\cdot)$ :

$$\begin{aligned} \frac{\partial l(\cdot)}{\partial \beta_1} &= 44 - \frac{48e^{\beta_1 + \beta_2}}{1 + e^{\beta_1 + \beta_2}} - \frac{52e^{\beta_1}}{1 + e^{\beta_1}} \\ \frac{\partial l(\cdot)}{\partial \beta_2} &= 12 - \frac{48e^{\beta_1 + \beta_2}}{1 + e^{\beta_1 + \beta_2}} \end{aligned}$$

Из условий первого порядка задачи максимизации:

$$42 - \frac{52e^{\hat{\beta}_1}}{1 + e^{\hat{\beta}_1}} = 12$$

Отсюда:

$$\hat{\beta}_1 = \log \left( \frac{8}{5} \right) \approx 0.47$$

$$\hat{\beta}_2 = \log \left( \frac{5}{24} \right) \approx -1.57$$

в) Можем сформулировать нулевую гипотезу:  $H_0 : \beta_2 = 0$

Нужно максимизировать логарифмическую функцию правдоподобия по  $\beta_1$  при ограничении  $\beta_2 = 0$ :

$$l^R(\beta_1, data) = 44\beta_1 - 100 \log(1 + e^{\beta_1})$$

$$\begin{aligned}\frac{\partial l(\cdot)}{\partial \beta_1} &= 44 - \frac{100e^{\beta_1}}{1 + e^{\beta_1}} \\ 44 - \frac{100e^{\hat{\beta}_1}}{1 + e^{\hat{\beta}_1}} &= 0 \\ \hat{\beta}_1 &= \log\left(\frac{11}{14}\right) \approx -0.24\end{aligned}$$

Здесь:

$$\hat{\beta}_{1,UR} = 0.47, \hat{\beta}_{2,UR} = -1.57, \hat{\beta}_{1,R} = -0.24, \hat{\beta}_{2,R} = 0$$

Применив тест отношения правдоподобия, получим:

$$LR = 2 \left( l(\hat{\beta}_{1,UR}, \hat{\beta}_{2,UR}) - l(\hat{\beta}_{1,R}, \hat{\beta}_{2,R}) \right) = 2(-61.63857 + 68.59298) \approx 13.91$$

```
p.value <- 1 - pchisq(13.91, df = 2)
p.value

## [1] 0.0009538539

p.value < 0.05

## [1] TRUE
```

Гипотеза отвергается. То есть на самом деле правильность меда связана с правильностью пчел.

г) Используем оценки коэффициентов для оценки необходимой вероятности:

$$\hat{\mathbb{P}}(\text{honey}_i = 0 \mid \text{bee}_i = 0) = \frac{1}{1 + e^{\hat{\beta}_{1,UR}}} = \frac{1}{1 + e^{0.47}} \approx 0.38$$

### Задача 6.5.

При оценке логит модели

$$\mathbb{P}(y_i = 1) = \Lambda(\beta_1 + \beta_2 x_i)$$

оказалось, что  $\hat{\beta}_1 = 0.7$  и  $\hat{\beta}_2 = 3$ . Найдите максимальный предельный эффект роста  $x_i$  на вероятность  $\mathbb{P}(y_i = 1)$ .

Решение.

$$\widehat{\mathbb{P}(y_i = 1)} = \Lambda(\hat{\beta}_1 + \hat{\beta}_2 x_i) = \frac{1}{(1 + e^{-(\hat{\beta}_1 + \hat{\beta}_2 x_i)})} = \frac{1}{1 + e^{-(\hat{\beta}_1 + \hat{\beta}_2 x_i)}}$$

Предельный эффект роста  $x_i$  на вероятность  $\mathbb{P}(y_i = 1)$ :

$$\frac{\partial \widehat{\mathbb{P}(y_i = 1)}}{\partial x_i} = \frac{\hat{\beta}_2 e^{-(\hat{\beta}_1 + \hat{\beta}_2 x_i)}}{(1 + e^{-(\hat{\beta}_1 + \hat{\beta}_2 x_i)})^2}$$

Максимизируем:

$$\frac{\partial^2 \mathbb{P}(y_i = 1)}{\partial x_i^2} = \hat{\beta}_2 \frac{-\hat{\beta}_2 e^{-(\hat{\beta}_1 + \hat{\beta}_2 x_i)} (1 + e^{-(\hat{\beta}_1 + \hat{\beta}_2 x_i)})^2 + 2(1 + e^{-(\hat{\beta}_1 + \hat{\beta}_2 x_i)}) e^{-(\hat{\beta}_1 + \hat{\beta}_2 x_i)} \hat{\beta}_2}{(1 + e^{-(\hat{\beta}_1 + \hat{\beta}_2 x_i)})^4} = 0$$

$$\begin{aligned}
1 + e^{-(\widehat{\beta}_1 + \widehat{\beta}_2 x_i)} &= 2 \\
\widehat{\beta}_1 + \widehat{\beta}_2 x_i &= 0 \\
x_i &= -\frac{\widehat{\beta}_1}{\widehat{\beta}_2}
\end{aligned}$$

Итак:

$$\hat{x}_i = -\frac{\widehat{\beta}_1}{\widehat{\beta}_2} \approx -0.23$$

Максимальный предельный эффект роста  $x_i$  на вероятность:

$$\frac{\partial \mathbb{P}(\widehat{y_i = 1})}{\partial x_i} = \frac{3e^{-(0.7+3 \cdot (-0.23))}}{(1 + e^{-(0.7+3 \cdot (-0.23))})^2} \approx 0.75$$

#### Задача 6.4.

Как известно, Фрекен Бок любит пить коньяк по утрам. За прошедшие 4 дня она записала, сколько рюмочек коньяка выпила утром,  $x_i$ , и видела ли она в этот день приведение,  $y_i$ :

$y_i$	1	0	1	0
$x_i$	2	1	3	0

Зависимость между  $y_i$  и  $x_i$  описывается логит моделью:

$$\log \left( \frac{\mathbb{P}(y_i = 1)}{\mathbb{P}(y_i = 0)} \right) = \beta_1 + \beta_2 x_i$$

а) Выпишите в явном виде логарифмическую функцию максимального правдоподобия

б) Найдите оценки параметров  $\beta_1$  и  $\beta_2$

Решение.

а) Логарифмическая функция максимального правдоподобия выглядит следующим образом:

$$l(\beta_1, \beta_2, data) = \sum \log \mathbb{P}(y_i | x_i)$$

Выпишем все вероятности, соответствующие данным из таблицы:

$$\mathbb{P}(y_i = 1 | x_i = 2) = \frac{e^{\beta_1 + 2\beta_2}}{1 + e^{\beta_1 + 2\beta_2}}$$

$$\mathbb{P}(y_i = 0 | x_i = 1) = \frac{1}{1 + e^{\beta_1 + \beta_2}}$$

$$\mathbb{P}(y_i = 1 | x_i = 3) = \frac{e^{\beta_1 + 3\beta_2}}{1 + e^{\beta_1 + 3\beta_2}}$$

$$\mathbb{P}(y_i = 0 | x_i = 0) = \frac{1}{1 + e^{\beta_1}}$$

$$\begin{aligned}
l(\beta_1, \beta_2, data) &= 2\beta_1 + 5\beta_2 - \log(1 + e^{\beta_1 + 2\beta_2}) - \log(1 + e^{\beta_1 + \beta_2}) - \\
&\quad - \log(1 + e^{\beta_1 + 3\beta_2}) - \log(1 + e^{\beta_1})
\end{aligned}$$

б)

```
loglik <- function(par) {
  b1 <- par[1]
  b2 <- par[2]
  ans <- 2*b1 + 5*b2 - log(1 + exp(b1 + 2*b2)) -
    log(1 + exp(b1 + b2)) -
    log(1 + exp(b1 + 3*b2)) -
    log(1 + exp(b1))
  return(ans)
}
```

```
result <- maxLik(logLik = loglik, start = c(0,0))
report <- summary(result)
report

## -----
## Maximum Likelihood estimation
## Newton-Raphson maximisation, 6 iterations
## Return code 1: gradient close to zero
## Log-Likelihood: -1.136868e-13
## 2 free parameters
## Estimates:
##      Estimate Std. error t value Pr(> t)
## [1,]   -369.7         Inf      0      1
## [2,]    267.0         Inf      0      1
## -----

result$estimate

## [1] -369.7451  267.0360
```

Наблюдается ситуация perfect prediction. Простое правило — если  $x_i > 1.5$ , то  $y_i = 1$ . Ситуация иногда наблюдается в логит моделях, когда много объясняющих переменных.

Грамотный выход из ситуации — Байесовский подход или получить дополнительное наблюдение (с последним сложнее).

Байесовский подход:  $\beta_1$  и  $\beta_2$  случайны.

$$\beta_i \sim N(0, 10^6)$$

Оценки получить апостериорно, они будут существовать.



## СЕМИНАР. FEBRUARY, 9

Нам потребуются функции *glm*(·) (Generalized Linear Model) и *maBina* (Marginal Effect for Binary Probit and Logit Model) из пакета *erer*:

```
library(erer) # glm
```

Загрузим данные из задачи 6.4., но с дополнительным наблюдением  $x_5 = 3$ ,  $y_5 = 0$  для того, чтобы избежать проблему perfect prediction:

```
df <- data.frame(x = c(2, 1, 3, 0, 3),  
                 y = c(1, 0, 1, 0, 0))
```

Оценим по этим данным логит и пробит модели. Для этого нужно выбрать аргумент *link*, соответствующий определенной модели классификации:

```
logit <- glm(data = df, y ~ x,  
             family = binomial(link = "logit"))  
summary(logit)  
  
##  
## Call:  
## glm(formula = y ~ x, family = binomial(link = "logit"), data = df)  
##  
## Deviance Residuals:  
##      1      2      3      4      5  
## 1.3443 -0.6454  0.9000 -0.3893 -1.4829  
##  
## Coefficients:  
##              Estimate Std. Error z value Pr(>|z|)  
## (Intercept)  -2.542      2.592  -0.981   0.327  
## x              1.079      1.091   0.989   0.323  
##  
## (Dispersion parameter for binomial family taken to be 1)  
##  
##      Null deviance: 6.7301  on 4  degrees of freedom  
## Residual deviance: 5.3844  on 3  degrees of freedom  
## AIC: 9.3844  
##  
## Number of Fisher Scoring iterations: 4
```

```
probit <- glm(data = df, y ~ x,  
             family = binomial(link = "probit"))  
summary(probit)  
  
##  
## Call:  
## glm(formula = y ~ x, family = binomial(link = "probit"), data = df)  
##
```

```
## Deviance Residuals:
##      1      2      3      4      5
##  1.3544 -0.6199  0.9030 -0.3300 -1.4793
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -1.6164     1.4617  -1.106   0.269
## x              0.6810     0.6258   1.088   0.277
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 6.7301  on 4  degrees of freedom
## Residual deviance: 5.3314  on 3  degrees of freedom
## AIC: 9.3314
##
## Number of Fisher Scoring iterations: 6
```

```
library(memisc)
```

```
## Loading required package: lattice
## Loading required package: MASS
##
## Attaching package: 'memisc'
##
## The following objects are masked from 'package:stats':
##
##      contr.sum, contr.treatment, contrasts
##
## The following object is masked from 'package:base':
##
##      as.array
```

```
mtable(logit, probit) # a table of estimates for several models
```

```
##
## Calls:
## logit: glm(formula = y ~ x, family = binomial(link = "logit"), data = df)
## probit: glm(formula = y ~ x, family = binomial(link = "probit"), data = df)
##
## =====
##              logit  probit
## -----
## (Intercept)    -2.542  -1.616
##                (2.592) (1.462)
## x              1.079   0.681
##                (1.091) (0.626)
## -----
## Aldrich-Nelson R-sq.    0.212   0.219
## McFadden R-sq.         0.200   0.208
## Cox-Snell R-sq.        0.236   0.244
```

```
## Nagelkerke R-sq.      0.319    0.330
## phi                  1.000    1.000
## Likelihood-ratio     1.346    1.399
## p                    0.246    0.237
## Log-likelihood       -2.692   -2.666
## Deviance              5.384    5.331
## AIC                   9.384    9.331
## BIC                   8.603    8.550
## N                     5        5
## =====
```

Заметим, что так как  $L(0, 1) \approx N(0, \pi^2/3)$ , то отношение коэффициентов в логит модели к коэффициентам в пробит модели приблизительно равно  $\sqrt{\pi}/3$ .

### Задача 1.

$$y_i = \begin{cases} 1, & \text{если } y_i^* \geq 0 \\ 0, & \text{если } y_i^* < 0 \end{cases}$$

Оценена логит модель:

$$\hat{y}_i^* = -2.542 + 1.079x_i$$

Прогноз на завтра:  $x_F = 2$ .

а) Найти  $\mathbb{P}(\widehat{y_F = 1})$

б) Построить 95-% доверительный интервал для  $\mathbb{P}(\widehat{y_F = 1})$  с использованием дельта-метода и без использования дельта-метода

Решение.

а)

$$\mathbb{P}(\widehat{y_F = 1}) = F(\hat{\beta}_1 + \hat{\beta}_2 x_F)$$

$F(\hat{\beta}_1 + \hat{\beta}_2 x_F)$  для логит модели — сигмоида в точке  $\hat{\beta}_1 + \hat{\beta}_2 x_F$ , для пробит модели — функция Лапласа в точке  $\hat{\beta}_1 + \hat{\beta}_2 x_F$ .

Для логит модели:

$$\mathbb{P}(\widehat{y_F = 1}) = \frac{e^{\hat{\beta}_1 + \hat{\beta}_2 x_F}}{1 + e^{\hat{\beta}_1 + \hat{\beta}_2 x_F}} \approx 0.405$$

```
hb1_l <- as.numeric(coef(logit)[1])
hb2_l <- as.numeric(coef(logit)[2])
hb1_p <- as.numeric(coef(probit)[1])
hb2_p <- as.numeric(coef(probit)[2])
# hb --- hat beta, l --- logit, p --- probit


xf <- 2

q_l <- hb1_l + hb2_l*xf
plogis(q_l)

## [1] 0.4050925
```

Построим графики  $\widehat{\mathbb{P}(y_F = 1)}$  и предельного эффекта  $x_F$ :  
 График  $\widehat{\mathbb{P}(y_F = 1)}$ :

```
all_x <- seq(-10, 10, by = 0.1)
all_p <- plogis(hb1_l + hb2_l*all_x)
qplot(all_x, all_p, geom = "line")
```




Предельный эффект  $x_F$ :

$$\frac{d\widehat{\mathbb{P}(y_F = 1)}}{dx_F} = f_{\varepsilon_i}(\hat{\beta}_1 + \hat{\beta}_2 x_F) \cdot \hat{\beta}_2$$

График предельного эффекта:

```
all_me <- dlogis(hb1_l + hb2_l*all_x)*hb2_l
qplot(all_x, all_me, geom = "line")
```



### б) Дельта-метод

Если  $\hat{\theta}_1, \dots, \hat{\theta}_n$  — оценки для параметра  $\theta$ ,  $g(\cdot)$  дифференцируема в  $\theta$  и

$$\sqrt{n} \left( \hat{\theta}_n - \theta \right) \xrightarrow{D} \mathcal{N}(0, \sigma^2)$$

то:

$$\sqrt{n} \left( g \left( \hat{\theta}_n \right) - g(\theta) \right) \xrightarrow{D} \mathcal{N}(0, \sigma^2 \cdot (g'(\theta))^2)$$

Для нашей задачи:

$$\hat{\beta} = \begin{pmatrix} -2.542 \\ 1.019 \end{pmatrix}$$

$$g(\hat{\beta}) = \mathbb{P}(\widehat{y_F} = 1) = \Lambda \left( \hat{\beta}_1 + \hat{\beta}_2 x_F \right)$$

При этом:

$$g(\beta) = \Lambda(\beta_1 + \beta_2 x_F)$$

Настало время дельта-метода:

$$\text{Var} \left( g(\hat{\beta}) \right) \approx \left( \frac{dg}{d\beta} \left( \hat{\beta} \right) \right)' \widehat{V} \left( \hat{\beta} \right) \left( \frac{dg}{d\beta} \left( \hat{\beta} \right) \right)$$

$$\frac{dg}{d\beta} \left( \hat{\beta} \right) = \begin{pmatrix} \frac{d\Lambda}{d\beta_1}(\hat{\beta}_1 + \hat{\beta}_2 x_F) \\ \frac{d\Lambda}{d\beta_2}(\hat{\beta}_1 + \hat{\beta}_2 x_F) \end{pmatrix} = \begin{pmatrix} f_{\varepsilon_i}(\hat{\beta}_1 + \hat{\beta}_2 x_F) \cdot 1 \\ f_{\varepsilon_i}(\hat{\beta}_1 + \hat{\beta}_2 x_F) \cdot x_F \end{pmatrix}$$

```
dgdb1 <- dlogis(hb1_l + hb2_l*xf)*1; dgdb1
## [1] 0.2409926

dgdb2 <- dlogis(hb1_l + hb2_l*xf)*xf; dgdb2
## [1] 0.4819851

grad <- c(dgdb1, dgdb2)
grad
## [1] 0.2409926 0.4819851

vcov(logit)

##           (Intercept)           x
## (Intercept)  6.719864 -2.584741
## x           -2.584741  1.189710

Var_g <- t(grad) %*% vcov(logit) %*% grad
Var_g <- as.numeric(Var_g); Var_g
## [1] 0.06619309

sqrt(Var_g)
## [1] 0.2572802
```

Проверим то, что мы получили с помощью функции `deltamethod(.)` из пакета *msm*, позволяющую сразу найти стандартное отклонение оценки:

```
library(msm) # delta method
deltamethod(~ 1/(1 + exp(-x1 - x2*xf)), c(hb1_1, hb2_1),
            vcov(logit))

## [1] 0.2572802
```

Теперь легко построить доверительный интервал, учитывая, что по дельта-методу оценка сходится по распределению к нормальному распределению:

```
low <- plogis(q_l) - qnorm(0.975)*sqrt(Var_g)
high <- plogis(q_l) + qnorm(0.975)*sqrt(Var_g)
conf <- data.frame(low, high)
conf

##           low      high
## 1 -0.09916737 0.9093524
```

Видим, что доверительный интервал выходит из области допустимых значений и имеет большой разброс. Но этот результат на основе дельта-метода стоило ожидать, так как очень мало наблюдений.

## СЕМИНАР. FEBRUARY, 16

Продолжение задачи с прошлого семинара.

Коэффициенты и ковариационная матрица коэффициентов для оцененной модели:

```
logit$coefficients

## (Intercept)          x
##   -2.541897    1.078803

vcov(logit)

##           (Intercept)          x
## (Intercept)   6.719864 -2.584741
## x             -2.584741  1.189710
```

Прогнозируем в случае  $x_F = 2$  или  $x_F = 4$ .

```
new <- data.frame(x = c(2, 4))
```

Можем получить оценку ненаблюдаемой склонности увидеть привидение:

```
pred <- predict(logit, newdata = new, se.fit = T)
pred

## $fit
##           1           2
## -0.3842904  1.7733160
##
## $se.fit
##           1           2
##  1.067586  2.253285
##
## $residual.scale
## [1] 1
```

Чтобы привести ее к вероятности, нужно применить функцию распределения логистического распределения:

```
plogis(pred$fit)

##           1           2
## 0.4050925 0.8548696
```

А можем сразу получить вероятность, прописав аргумент *type*:

```
pred2 <- predict(logit, newdata = new, type = 'response')
pred2

##           1           2
## 0.4050925 0.8548696
```

Построим доверительный интервал для прогноза для ненаблюдаемой склонности:

$$\hat{y}_F^* = \hat{\beta}_1 + \hat{\beta}_2 x_F$$

$$\mathbb{E}(\hat{y}_F^* | x_F) = \beta_1 + \beta_2 x_F$$

$$\text{Var}(\hat{y}_F^* | x_F) = \text{Var}(\hat{\beta}_1) + x_F^2 \text{Var}(\hat{\beta}_2) + 2x_F \text{Cov}(\hat{\beta}_1, \hat{\beta}_2)$$

$$\hat{y}_F^* | x_F \sim \mathcal{N}(\beta_1 + \beta_2 x_F, \text{Var}(\hat{y}_F^* | x_F))$$

Например, для  $x_F = 2$ :

```
var.hat <- vcov(logit)[1, 1] + 2^2*vcov(logit)[2, 2] + 2*2*vcov(logit)[2, 1]
var.hat

## [1] 1.139739

sqrt(var.hat)

## [1] 1.067586
```

То же самое мы получили в нашем прогнозе:

```
pred_df <- as.data.frame(pred)
pred_df

##           fit    se.fit residual.scale
## 1 -0.3842904 1.067586                1
## 2  1.7733160 2.253285                1
```

Новые значения объясняющей переменной:

```
pred_df$x <- c(2, 4)
pred_df

##           fit    se.fit residual.scale x
## 1 -0.3842904 1.067586                1 2
## 2  1.7733160 2.253285                1 4
```

Строим доверительный интервал для склонности увидеть привидение и несимметричный доверительный интервал для вероятности увидеть привидение:

```
library(dplyr)

##
## Attaching package: 'dplyr'
##
## The following objects are masked from 'package:memisc':
##
##   collect, query, rename
##
## The following object is masked from 'package:MASS':
##
```



```
##      select
##
## The following object is masked from 'package:stats':
##
##      filter
##
## The following objects are masked from 'package:base':
##
##      intersect, setdiff, setequal, union

pred_df <- pred_df %>%
  mutate(left_ci = fit - qnorm(0.975)*se.fit,
         right_ci = fit + qnorm(0.975)*se.fit) %>%
  mutate(left_ci_p = plogis(left_ci),
         right_ci_p = plogis(right_ci),
         p_hat = plogis(fit))
pred_df
```

Теперь построим симметричный доверительный интервал для вероятности, используя дельта-метод:

```
pred_df <- pred_df %>%
  mutate(se_DM = se.fit*dlogis(fit)) %>%
  mutate(left_ci_p_DM = p_hat - qnorm(0.975)*se_DM,
         right_ci_p_DM = p_hat + qnorm(0.975)*se_DM)
pred_df
```

	fit	se.fit	residual.scale	x	left_ci	right_ci	left_ci_p
## 1	-0.3842904	1.067586		1 2	-2.476720	1.708139	0.07750642
## 2	1.7733160	2.253285		1 4	-2.643042	6.189674	0.06641918

	right_ci_p	p_hat	se_DM	left_ci_p_DM	right_ci_p_DM
## 1	0.8465947	0.4050925	0.2572802	-0.09916737	0.9093524
## 2	0.9979537	0.8548696	0.2795597	0.30694269	1.4027964

Посмотрим на предельный эффект  $x_i$  на вероятность увидеть привидение:

```
library(erer)
logit_w_memory <- glm(data = df, y ~ x,
                      family = binomial(link = "logit"),
                      x = TRUE)
maBina(logit_w_memory)
```

	effect	error	t.value	p.value
## (Intercept)	-0.582	0.477	-1.218	0.310
## x	0.247	0.233	1.060	0.367

```
maBina(logit_w_memory, x.mean = F)
```

```
##          effect error t.value p.value  
## (Intercept) -0.460 0.378  -1.218   0.310  
## x           0.195 0.184   1.060   0.367
```